UNIDAD II

EXPLORACIÓN Y DIAGNÓSTICO DEL DATASET

Clasificación automática y análisis morfológico de variedades de frijol

ASIGNATURA	Extracción de Conocimiento en Bases de Datos
ACTIVIDAD	Evaluación 1 - Unidad II
ESTUDIANTE	Kevin Hernandez Trejo
MATRÍCULA	23300950
GRUPO Y CARRERA	10IDGS-G1
DOCENTE	Ing. Jose Luis Herrera Gallardo, MTI
FECHA	9 de noviembre de 2026
REPOSITORIO	github.com/Kaysito/REC_ECBD_2026_Hernandez_Trejo_Kevin

Informe técnico elaborado sobre el archivo original conservado sin modificaciones en data/raw/.

Índice

1. Resumen ejecutivo
2. Identificación y fuente
3. Estructura y exploración
4. Diccionario de datos
5. Diagnóstico de calidad
6. Estadística descriptiva
7. Valores atípicos
8. Visualizaciones
9. Propuestas analíticas
10. Conclusiones
11. Referencias

1. Resumen ejecutivo

El Dry Bean Dataset contiene 13,611 granos descritos por 16 mediciones morfológicas y una etiqueta de siete variedades. La revisión del archivo crudo encontró 100% de completitud, tipos coherentes, ausencia de valores negativos o proporciones fuera de rango y 68 duplicados exactos (0.500%), todos asociados a HOROZ. Los valores extremos detectados por IQR son plausibles y se conservan. El conjunto es adecuado para continuar con clasificación, regresión y clustering, siempre que posteriormente se controle la duplicación, el desbalance y la fuga de información.

Hallazgos principales

- 13,611 filas y 17 columnas.
- 16 variables numéricas y una variable nominal, Class.
- 0 valores faltantes y 68 duplicados exactos.
- Siete clases con desbalance: DERMASON 3,546 y BOMBAY 522.
- El SHA-256 del original es a9efa69741c6c5d95167c962a13da23a456f7e940402a5add12639790e01f714.

2. Identificación y fuente de los datos

Elemento	Resultado
Proyecto	Clasificación automática y análisis morfológico de variedades de frijol
Dataset	Dry Bean Dataset
Fuente	UCI Machine Learning Repository, ID 602
Formato usado	Microsoft Excel (.xlsx)
Dimensiones	13,611 registros × 17 variables
Origen	Mediciones biométricas/morfológicas generadas por máquina tras segmentar imágenes de granos
Estructura	Estructurada: tabla con esquema fijo de filas y columnas
Licencia	Creative Commons Attribution 4.0

Cada fila representa un grano fotografiado. Las variables describen tamaño, ejes, proporciones y factores de forma; Class registra la variedad. Aunque el origen inmediato son imágenes, el archivo entregado ya es una tabla estructurada de características extraídas por visión por computadora.

3. Estructura y exploración con Pandas

Instrucción	Resultado e interpretación
df.head()	Muestra cinco observaciones y confirma el esquema: 16 mediciones numéricas y Class.
df.shape	Devuelve (13611, 17): 13,611 granos y 17 columnas.
df.columns	Lista los nombres originales; AspectRation y roundness requieren normalización posterior de nomenclatura.
df.info()	Todas las columnas tienen 13,611 valores no nulos; 2 enteras, 14 float y 1 texto.
df.dtypes	Confirma tipos adecuados; no hay números almacenados como texto.
df.describe()	Resume conteo, media, dispersión, cuartiles y extremos; revela escalas muy diferentes.

La exploración se realizó sobre el Excel original mediante pd.read_excel(). El DataFrame reside en memoria; no se ejecutaron drop_duplicates(), fillna(), rename() ni operaciones de escritura sobre data/raw/.

4. Diccionario y clasificación de variables

Variable	Descripción	Python	Tipo / clase	Unidad	Utilidad
Area	Área interna del grano	int64	Cuantitativa / discreta	px²	Objetivo de regresión / tamaño
Perimeter	Longitud del contorno	float64	Cuantitativa / continua	px	Predictor morfológico
MajorAxisLength	Eje mayor	float64	Cuantitativa / continua	px	Predictor morfológico
MinorAxisLength	Eje menor	float64	Cuantitativa / continua	px	Predictor morfológico
AspectRation	Razón eje mayor/eje menor	float64	Cuantitativa / continua	Adimensional	Predictor morfológico
Eccentricity	Excentricidad de elipse equivalente	float64	Cuantitativa / continua	Adimensional	Predictor morfológico
ConvexArea	Área de envolvente convexa	int64	Cuantitativa / discreta	px²	Predictor morfológico
EquivDiameter	Diámetro de círculo equivalente	float64	Cuantitativa / continua	px	Predictor morfológico
Extent	Área respecto a caja delimitadora	float64	Cuantitativa / continua	Adimensional	Predictor morfológico
Solidity	Area/ConvexArea	float64	Cuantitativa / continua	Adimensional	Predictor morfológico
roundness	Redondez $4\pi A/P^2$	float64	Cuantitativa / continua	Adimensional	Predictor morfológico
Compactness	EquivDiameter/eje mayor	float64	Cuantitativa / continua	Adimensional	Predictor morfológico
ShapeFactor1	Factor morfológico 1	float64	Cuantitativa / continua	Adimensional	Predictor morfológico
ShapeFactor2	Factor morfológico 2	float64	Cuantitativa / continua	Adimensional	Predictor morfológico
ShapeFactor3	Factor morfológico 3	float64	Cuantitativa / continua	Adimensional	Predictor morfológico
ShapeFactor4	Factor morfológico 4	float64	Cuantitativa / continua	Adimensional	Predictor morfológico
Class	Variedad registrada	str	Cualitativa / nominal	Categoría	Objetivo de clasificación

5. Diagnóstico de calidad

5.1 Completitud

df.isnull().sum() reporta cero faltantes en las 17 columnas. La completitud es 100%; no se propone imputación para este archivo.

5.2 Duplicados

df.duplicated().sum() identifica 68 duplicados exactos, equivalentes al 0.500% del conjunto. Las 136 filas involucradas en pares repetidos pertenecen a HOROZ. La causa puede ser repetición durante captura o consolidación. En una copia procesada se conservará una sola observación de cada duplicado antes de separar entrenamiento y prueba.

5.3 Inconsistencias

Control	Incidencias
Valores numéricos negativos	0
Eccentricity fuera de [0,1)	0
Extent, Solidity, roundness o Compactness fuera de (0,1]	0
Clases vacías, con espacios o desconocidas	0
Nombres no estandarizados	AspectRation y roundness

No se modificó ningún valor. Los nombres se documentan ahora y se normalizarán únicamente en una copia procesada.

6. Análisis estadístico inicial

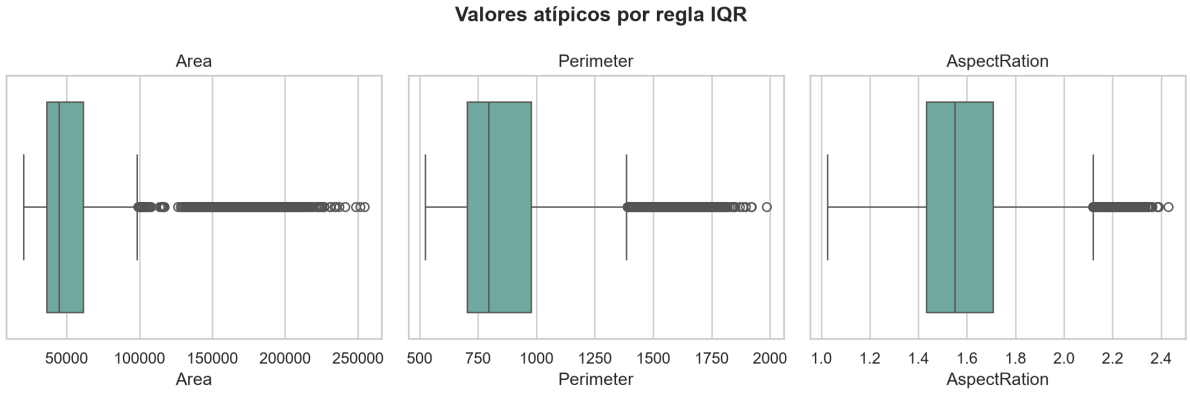
Variable	Media	Mediana	Mínimo	Máximo	Desv. estándar
Area	53,048.285	44,652.000	20,420.000	254,616.000	29,324.096
Perimeter	855.283	794.941	524.736	1,985.370	214.290
AspectRation	1.583	1.551	1.025	2.430	0.247

Area y Perimeter presentan medias superiores a sus medianas, señal de asimetría hacia granos grandes. AspectRation varía entre 1.025 y 2.430, diferenciando formas casi redondas de granos alargados. Las variables resumen tamaño, contorno y proporción, tres dimensiones centrales del proyecto.

Distribución de clases

Clase	Registros	Porcentaje
DERMASON	3,546	26.05%
SIRA	2,636	19.37%
SEKER	2,027	14.89%
HOROZ	1,928	14.17%
CALI	1,630	11.98%
BARBUNYA	1,322	9.71%
BOMBAY	522	3.84%

7. Detección inicial de valores atípicos



Variable	Límite inferior	Límite superior	Casos IQR	Porcentaje
Area	-1,178.000	98,838.000	551	4.05%
Perimeter	292.989	1,387.747	500	3.67%
AspectRation	1.020	2.119	473	3.48%

Los boxplots señalan 551 casos en Area, 500 en Perimeter y 473 en AspectRation. No se consideran errores por defecto: pertenecen a un dataset multiclase, son positivos y respetan rangos físicos. Se conservarán y se estudiarán por variedad antes de aplicar transformaciones robustas.

8. Visualización e interpretación

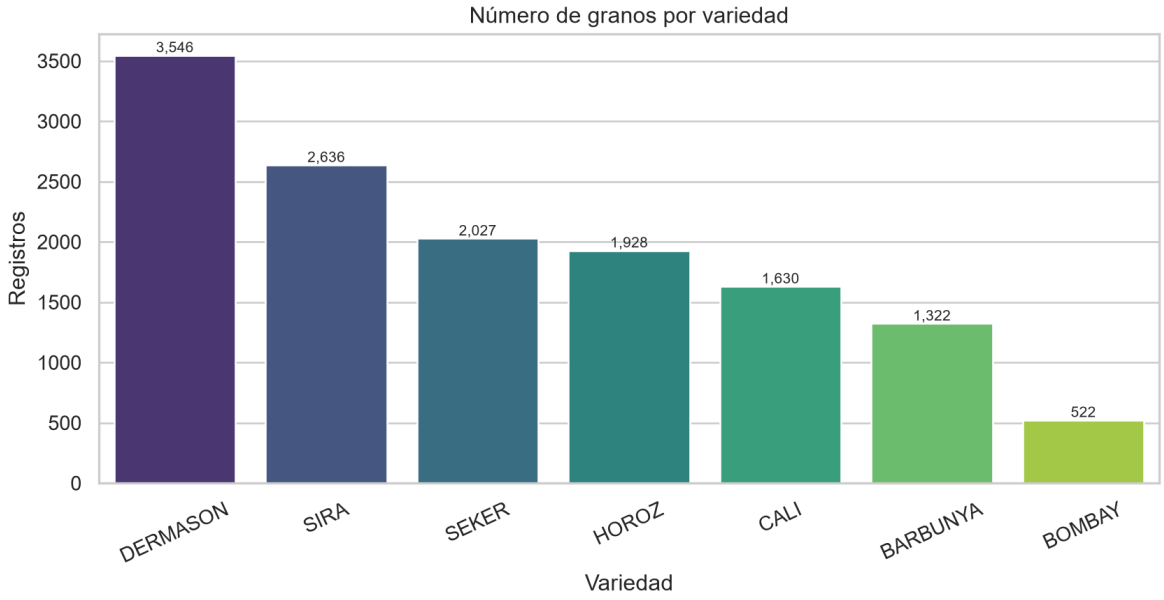


Figura 1. DERMASON es la clase más numerosa y BOMBAY la minoritaria. La diferencia exige estratificación y métricas como macro F1 para no ocultar el desempeño de clases pequeñas.

8. Visualización e interpretación

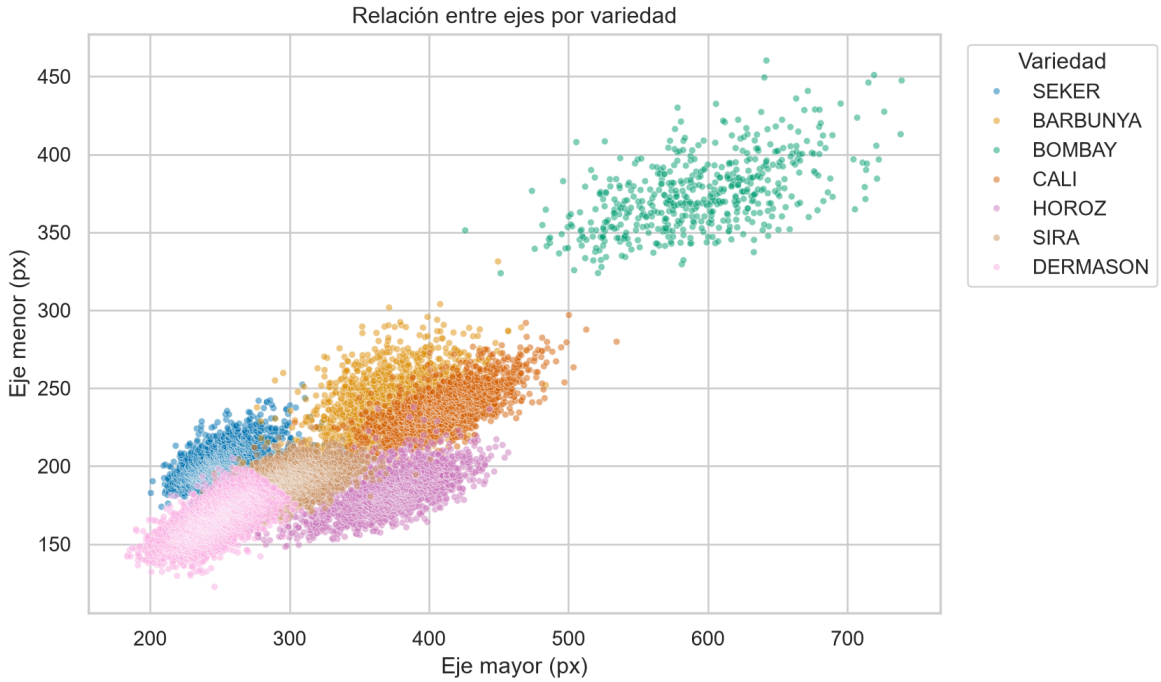


Figura 2. Los ejes mayor y menor aumentan juntos. Algunas variedades ocupan regiones distintas por tamaño, pero hay solapamientos que justifican combinar medidas de tamaño con descriptores de forma.

8. Visualización e interpretación

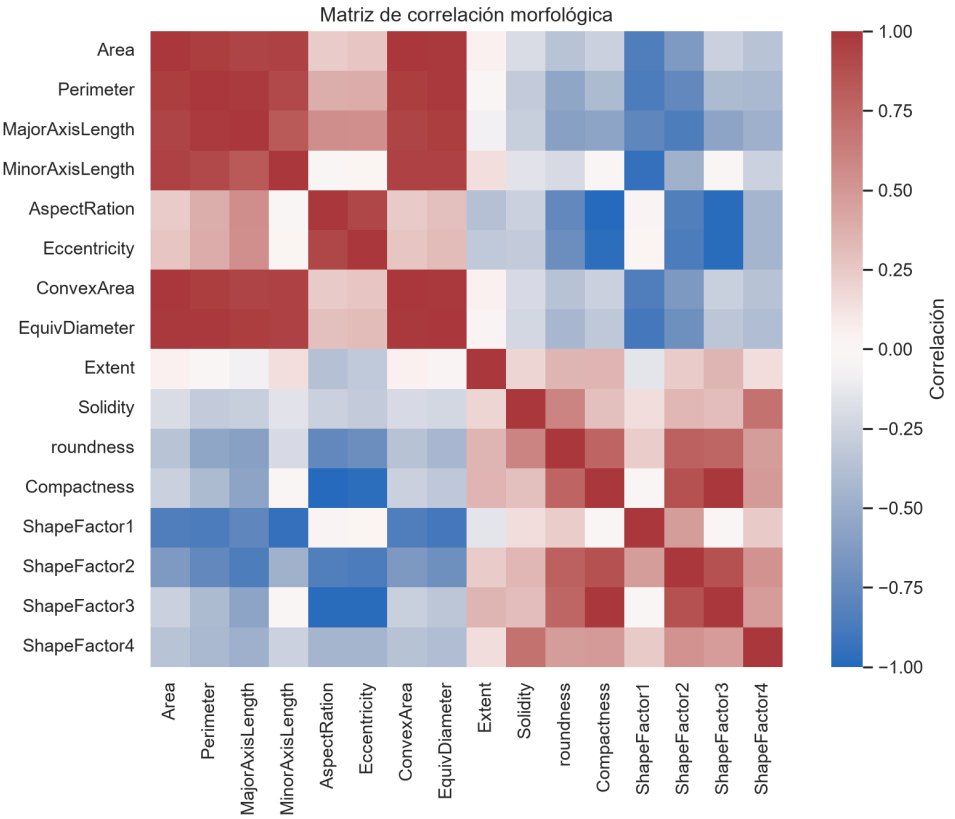


Figura 3. Area, ConvexArea y EquivDiameter tienen correlación elevada por construcción geométrica. Para una regresión honesta de Area se excluye EquivDiameter y se revisa ConvexArea para prevenir fuga de información.

9. Preparación para análisis posteriores

Tarea	Objetivo / variables	Justificación y control
Regresión	Objetivo: Area. Entradas: Perimeter, ejes, proporciones y factores de forma.	Estimar tamaño. Excluir EquivDiameter y revisar ConvexArea por dependencia directa.
Clasificación	Objetivo: Class. Siete variedades; entradas: 16 medidas numéricas.	Responde al proyecto de clasificación automática. Usar estratificación y macro F1.
Agrupamiento	Sin etiqueta; tamaño, ejes, AspectRation, Eccentricity, Extent, Solidity, redondez, compacidad y factores.	Buscar perfiles naturales. Deduplicar y estandarizar antes de usar distancias; contrastar después con Class.

Estas propuestas mantienen la relación con Unidad I: explicar y distinguir variedades mediante morfología, estimar una propiedad continua y descubrir estructuras sin usar etiquetas.

10. Conclusión del diagnóstico

1. ¿Qué contiene? 13,611 granos, 16 medidas morfológicas y Class.
2. ¿Calidad general? Alta: 100% de completitud, tipos coherentes y rangos plausibles.
3. ¿Problemas? 68 duplicados, desbalance, nomenclatura no uniforme y valores extremos por IQR.
4. ¿Qué requiere tratamiento? Duplicados en copia procesada, nombres, escalas y variables derivadas para regresión.
5. ¿Faltantes? No.
6. ¿Duplicados? Sí: 68, todos vinculados con HOROZ.
7. ¿Atípicos? Sí según IQR, pero plausibles; no se eliminan.
8. ¿Transformaciones? Deduplicación, normalización de nombres, escalado cuando corresponda y separación de objetivos.
9. ¿Adecuado? Sí, con controles de fuga, desbalance y evaluación por clase.
10. ¿Conocimiento futuro? Rasgos que separan variedades, errores entre clases, estimación de tamaño y grupos naturales.

Integridad del original

La huella SHA-256 se verificó antes y después del análisis: **a9efa69741c6c5d95167c962a13da23a456f7e940402a5add12639790e01f714**. El archivo original permaneció intacto en data/raw/.

Fuentes de información

Koklu, M., & Özkan, I. A. (2020). Multiclass classification of dry beans using computer vision and machine learning techniques. Computers and Electronics in Agriculture, 174, 105507. https://doi.org/10.1016/j.compag.2020.105507

UCI Machine Learning Repository. (2020). Dry Bean [Data set]. https://doi.org/10.24432/C50S4B

Repositorio actualizado

https://github.com/Kaysito/REC_ECBD_2026_Hernandez_Trejo_Kevin

El notebook ejecutable se almacena en notebooks/ y este informe en docs/, conforme a la estructura solicitada.