EDUCACIÓN VIRTUAL

PROGRAMA EDUCATIVO:

INGENIERIA EN DESARROLLO Y GESTION DE SOFTWARE

ASIGNATURA:

EXTRACCION DE CONOCIMIENTO EN BASES DE DATOS

TEMA

CLASIFICACION AUTOMATICA Y ANALISIS MORFOLOGICO DE VARIEDADES DE FRIJOL



ACTIVIDAD 0

Kevin Hernandez Trejo | 23300950 | 10IDGS-G1

28 de septiembre de 2026

Inicio y registro del proyecto

Estudiante	Kevin Hernandez Trejo
Matrícula	23300950
Grupo y carrera	10IDGS-G1
Docente	Ing. Jose Luis Herrera Gallardo, MTI
Proyecto	Clasificacion automatica y analisis morfologico de variedades de frijol
Dataset	Dry Bean Dataset
Fuente	UCI Machine Learning Repository
Enlace oficial	https://archive.ics.uci.edu/dataset/602/dry+bean

Descripción del problema

El proyecto estudiará si las mediciones geométricas obtenidas de imágenes de granos permiten reconocer automáticamente la variedad de frijol. Varias variedades comparten rasgos visuales similares, por lo que una clasificación manual puede ser lenta o inconsistente. Se analizarán el tamaño, las proporciones y la forma de cada grano para identificar las características que mejor separan las siete variedades y, posteriormente, construir modelos que apoyen una clasificación uniforme.

Revisión inicial

Registros	13,611 observaciones
Variables	17 columnas: 16 predictoras numericas y 1 objetivo categorico
Clases	BARBUNYA, BOMBAY, CALI, DERMASON, HOROZ, SEKER y SIRA
Valores faltantes	0 valores faltantes detectados
Duplicados	68 filas duplicadas exactas; se revisaran en la etapa de preparacion

Preguntas que pueden responderse

1. ¿Que caracteristicas morfologicas permiten distinguir mejor las siete variedades de frijol?

2. ¿Con que precision puede predecirse la variedad de un grano utilizando sus mediciones geometricas?

3. ¿Existen agrupamientos naturales que coincidan con las variedades registradas o revelen perfiles morfologicos compartidos?

Descripción preliminar de las variables

Variable	Tipo	Descripción preliminar
Area	Entera	Area ocupada por el grano, medida como numero de pixeles.
Perimeter	Continua	Longitud del contorno o borde del grano.
MajorAxisLength	Continua	Longitud del eje principal, la mayor distancia longitudinal del grano.
MinorAxisLength	Continua	Longitud del eje menor, perpendicular al eje principal.
AspectRation	Continua	Relacion entre los ejes mayor y menor; expresa el alargamiento.
Eccentricity	Continua	Eccentricidad de la elipse equivalente; indica cuanto se aparta de un circulo.
ConvexArea	Entera	Area del poligono convexo minimo que contiene al grano.
EquivDiameter	Continua	Diametro del circulo que tendria la misma area que el grano.
Extent	Continua	Proporcion entre el area del grano y su caja delimitadora.
Solidity	Continua	Relacion entre el area real y el area convexa; representa la solidez de la forma.
roundness	Continua	Medida de redondez calculada a partir del area y el perimetro.
Compactness	Continua	Medida de compacidad que relaciona el diametro equivalente y el eje mayor.
ShapeFactor1	Continua	Primer factor numerico derivado de la geometria del grano.
ShapeFactor2	Continua	Segundo factor numerico derivado de la geometria del grano.
ShapeFactor3	Continua	Tercer factor numerico derivado de la geometria del grano.
ShapeFactor4	Continua	Cuarto factor numerico derivado de la geometria del grano.
Class	Categorica	Variedad registrada del frijol; variable categorica con siete clases.

Variables para predicción

Objetivo de clasificación

Se utilizara Class como variable objetivo para predecir la variedad del frijol. Las variables predictoras iniciales seran las 16 mediciones de tamano, proporcion y forma. Es una clasificacion multiclase porque la salida puede pertenecer a siete categorias.

Objetivo de regresión

Se propone Area como variable objetivo continua. Las variables predictoras se seleccionaran entre las medidas de ejes, proporcion, eccentricidad, extension, solidez, redondez, compacidad y factores de forma. ConvexArea y EquivDiameter se revisaran cuidadosamente o se excluiran, porque mantienen una relacion directa con el area y podrian causar fuga de informacion.

Hallazgos iniciales

- El conjunto esta completo: no se detectaron valores faltantes.

- La clase mas frecuente es DERMASON con 3,546 registros y la menos frecuente es BOMBAY con 522; por ello sera necesario evaluar el desbalance de clases.

- Se encontraron 68 duplicados exactos. No se eliminaran del archivo original; su tratamiento se documentara en data/processed.

- Los nombres AspectRation y roundness presentan una convencion distinta al resto. Se conservaran en data/raw y podran normalizarse solamente en la version procesada.

Repositorio del proyecto

Pendiente de publicacion en GitHub

Fuente y atribucion

Koklu, M. y Ozkan, I. A. (2020). Dry Bean Dataset. UCI Machine Learning Repository. DOI: 10.24432/C50S4B. Licencia CC BY 4.0.

Evidencia de descarga y apertura

La siguiente vista corresponde al archivo original Dry_Bean_Dataset.xlsx, descargado desde UCI y abierto mediante pandas para realizar la inspeccion inicial. Se muestran las primeras filas y seis columnas representativas.

Dry_Bean_Dataset.xlsx - Vista preliminar con pandas

Dimensiones: 13,611 filas x 17 columnas | Valores faltantes: 0

Indice	Area	Perimeter	MajorAxisLength	MinorAxisLength	AspectRation	Class
0	28395	610.291	208.178	173.889	1.197	SEKER
1	28734	638.018	200.525	182.734	1.097	SEKER
2	29380	624.110	212.826	175.931	1.210	SEKER
3	30008	645.884	210.558	182.517	1.154	SEKER
4	30140	620.134	201.848	190.279	1.061	SEKER
5	30279	634.927	212.561	181.510	1.171	SEKER
6	30477	670.033	211.050	184.039	1.147	SEKER
7	30519	629.727	212.997	182.737	1.166	SEKER

Figura 1. Vista preliminar del dataset descargado y abierto correctamente.

Ubicacion local	data/raw/dry_bean_dataset/DryBeanDataset/Dry_Bean_Dataset.xlsx
Archivo original	dry_bean_dataset.zip conservado sin modificaciones
Integridad	Archivo ZIP verificado correctamente
Dimensiones comprobadas	13,611 filas por 17 columnas
Repositorio	Pendiente de publicacion en GitHub

Esta revision inicial confirma que el conjunto de datos corresponde al proyecto asignado y que esta disponible para continuar con las etapas de exploracion, preparacion, modelado supervisado, analisis no supervisado y visualizacion.