EDUCACIÓN Ed VIRTUAL viut

PROGRAMA EDUCATIVO:

UNIDAD I

PLANEACIÓN DEL PROYECTO

Clasificación automática y análisis morfológico de variedades de frijol

ASIGNATURA	Extracción de Conocimiento en Bases de Datos
MODALIDAD	Recursamiento 2026
ESTUDIANTE	Kevin Hernandez Trejo
MATRÍCULA	23300950
GRUPO Y CARRERA	10IDGS-G1
DOCENTE	Ing. Jose Luis Herrera Gallardo, MTI
FECHA	2 de octubre de 2026

Universidad Tecnológica de Tula-Tepeji



UNIDAD

ESPACIO DE APRENDIZAJE VIRTUAL

1. Síntesis ejecutiva

Este proyecto estudia si las mediciones geométricas obtenidas mediante visión por computadora permiten distinguir automáticamente siete variedades de frijol seco. El conjunto Dry Bean reúne 13,611 observaciones y 16 atributos numéricos de tamaño y forma, además de la etiqueta de variedad. La planeación integra exploración, preparación, clasificación, regresión y análisis no supervisado, con trazabilidad en GitHub y una futura comunicación de resultados mediante un tablero.

PREGUNTA RECTORA	**¿Con qué precisión pueden clasificarse las siete variedades de frijol a partir de sus características morfológicas, y cuáles de esas características explican mejor la separación entre clases?**

Contexto y descripción del problema

La clasificación de semillas por inspección visual depende de experiencia humana y puede volverse lenta o inconsistente cuando las variedades presentan formas parecidas. En el caso estudiado, un sistema de visión por computadora segmentó imágenes de granos y calculó descriptores morfológicos. El reto es transformar esas mediciones en conocimiento útil: reconocer la variedad, entender qué rasgos contribuyen a la decisión y detectar patrones que no sean evidentes a simple vista (Koklu & Özkan, 2020; UCI, 2020).

Planteamiento del problema

No se conoce todavía qué combinación de variables ofrece el mejor equilibrio entre precisión, estabilidad e interpretabilidad para separar las siete clases. Además, el conjunto presenta clases desiguales y 68 registros duplicados exactos; si estos aspectos no se controlan, la evaluación puede ser optimista. Por ello se requiere un proceso reproducible que conserve el archivo original, analice la calidad de los datos, evite fuga de información y compare modelos con métricas adecuadas.

2. Objetivos, alcance y límites

Objetivo general

Desarrollar y evaluar un proceso reproducible de análisis de datos que clasifique siete variedades de frijol seco y explique sus diferencias morfológicas, utilizando el conjunto Dry Bean y la metodología CRISP-DM durante el periodo de recursamiento 2026.

Objetivos específicos

- Examinar las 13,611 observaciones y 17 columnas para documentar tipos, distribuciones, calidad, duplicados, valores atípicos y relaciones entre variables.
- Construir un flujo de preparación reproducible que trate duplicados, escale variables cuando el algoritmo lo requiera y separe entrenamiento y prueba de forma estratificada.
- Entrenar y comparar al menos tres clasificadores multiclase mediante validación cruzada, accuracy, macro F1 y matriz de confusión.
- Estimar la variable Area con modelos de regresión, excluyendo predictores derivados directamente de ella cuando puedan producir fuga de información, y evaluar con MAE, RMSE y R^2.
- Explorar agrupamientos naturales y reducción de dimensionalidad mediante clustering y PCA, y contrastar los grupos con las variedades registradas.
- Comunicar resultados, limitaciones y evidencia reproducible en el repositorio, el informe técnico y un tablero final.

Alcance

El trabajo abarcará análisis exploratorio, limpieza, transformación, modelado supervisado y no supervisado, evaluación técnica, interpretación y visualización. La unidad de análisis es cada grano fotografiado. El producto será un prototipo analítico académico; no incluye la captura de imágenes nuevas ni la integración en una línea industrial.

Limitaciones y riesgos

Limitación	Efecto esperado	Tratamiento previsto
Datos de un estudio controlado	La precisión puede no generalizar a otras cámaras, regiones o cosechas.	Declarar el dominio y proponer validación externa.
Desbalance de clases	Una clase numerosa puede dominar accuracy.	División estratificada y macro F1 por clase.
68 duplicados exactos	Posible evaluación optimista si aparecen en ambos subconjuntos.	Deduplicar antes de dividir y documentar el cambio.
Variables derivadas	Riesgo de fuga en la regresión de Area.	Excluir EquivDiameter y revisar ConvexArea; comparar con un escenario controlado.

3. Conjunto de datos

Inventario verificado del archivo original conservado en data/raw.

Elemento	Descripción
Nombre	Dry Bean Dataset
Procedencia	UCI Machine Learning Repository; publicado por Koklu y Özkan.
Identificador / DOI	UCI ID 602 · https://doi.org/10.24432/C50S4B
Tamaño	13,611 registros; 17 columnas: 16 predictoras y 1 clase.
Tipos	2 enteras (Area, ConvexArea), 14 reales y 1 categórica (Class).
Calidad inicial	Sin valores faltantes; 68 filas duplicadas exactas detectadas.
Clases	BARBUNYA, BOMBAY, CALI, DERMASON, HOROZ, SEKER y SIRA.
Licencia	Creative Commons Attribution 4.0 (CC BY 4.0).

Descripción de variables

Grupo	Variables	Interpretación preliminar
Tamaño	Area, Perimeter, MajorAxisLength, MinorAxisLength, ConvexArea, EquivDiameter	Dimensiones del grano y de su envolvente; son medidas en píxeles o longitudes derivadas.
Proporción	AspectRatio, Eccentricity, Extent, Solidity	Alargamiento, semejanza con una elipse, ocupación de la caja y convexidad.
Forma	roundness, Compactness, ShapeFactor1, ShapeFactor2, ShapeFactor3, ShapeFactor4	Descriptores adimensionales que resumen circularidad y geometría.
Etiqueta	Class	Variedad registrada; objetivo natural de clasificación multiclase.

La distribución no es uniforme: DERMASON contiene 3,546 registros y BOMBAY 522. Esta diferencia obliga a reportar métricas por clase. UCI documenta 16 atributos obtenidos tras segmentación y extracción de características de imágenes de alta resolución (UCI Machine Learning Repository, 2020).

Variables objetivo propuestas

Tarea	Objetivo	Predictores y criterio
Clasificación	Class (7 categorías)	Las 16 medidas numéricas; comparar modelos multiclase con validación estratificada.
Regresión	Area (continua)	Perimeter, ejes y factores de forma. Excluir EquivDiameter por fórmula directa y revisar ConvexArea por alta dependencia geométrica.
No supervisado	Sin etiqueta	Variables estandarizadas; PCA para representación y clustering para grupos naturales.

4. Comparación conceptual I

Inteligencia Artificial y Machine Learning dentro del proyecto.

Criterio	Inteligencia Artificial (IA)	Machine Learning (ML)
Definición	Campo amplio que diseña sistemas capaces de producir predicciones, recomendaciones o decisiones para objetivos humanos.	Subcampo de la IA en el que algoritmos aprenden patrones a partir de datos para estimar resultados sin programar cada regla.
Características	Integra percepción, razonamiento, aprendizaje, planificación e interacción; puede combinar reglas y modelos.	Depende de variables, ejemplos, función de pérdida, generalización y evaluación con datos no vistos.
Beneficios	Automatiza decisiones complejas, amplía capacidad humana y permite respuestas consistentes a escala.	Descubre relaciones no lineales, mejora con evidencia y permite predicción cuantificable.
Restricciones	Calidad de datos, explicabilidad, sesgos, seguridad, privacidad y supervisión humana.	Sobreajuste, fuga de información, desbalance, cambios de distribución y dependencia del muestreo.
Retos	Gobernanza, confiabilidad, responsabilidad y uso adecuado fuera del laboratorio.	Selección de variables, ajuste de hiperparámetros, métricas y reproducibilidad.
Aplicación aquí	Sistema de apoyo para clasificación morfológica de granos.	Clasificadores, regresores, PCA y clustering sobre las mediciones del dataset.
Herramientas	Python, reglas de decisión, APIs y tableros de apoyo.	scikit-learn, pandas, NumPy, Jupyter, MLflow opcional.

Relación: ML es una vía para construir capacidades de IA, pero no toda IA requiere aprendizaje estadístico. En este proyecto el núcleo técnico es ML; el término IA describe el sistema de apoyo resultante y no implica autonomía total. NIST destaca que la gestión de riesgos debe acompañar el diseño, desarrollo, despliegue y uso responsable de sistemas de IA (Tabassi, 2023).

5. Comparación conceptual II

Data Mining y Big Data: propósito, escala y pertinencia.

Criterio	Data Mining	Big Data
Definición	Proceso de descubrir patrones útiles y conocimiento en conjuntos de datos mediante técnicas estadísticas, computacionales y de ML.	Arquitecturas y prácticas para almacenar, integrar y procesar datos cuyo volumen, velocidad, variedad o complejidad superan soluciones convencionales.
Características	Orientado a preguntas, patrones, segmentación, asociación, anomalías y predicción.	Escala distribuida, procesamiento paralelo, datos heterogéneos y gobierno del ciclo de vida.
Beneficios	Convierte datos en explicaciones, reglas o segmentos accionables.	Permite procesar grandes flujos y fuentes que no caben o no responden bien en un solo equipo.
Restricciones	Los patrones pueden ser espurios; exige calidad, validación y conocimiento del dominio.	Costo, complejidad operativa, latencia, seguridad y escasez de habilidades especializadas.
Retos	Interpretabilidad, preparación, métricas y traducción a decisiones.	Integración, calidad, metadatos, consistencia y elección de infraestructura proporcional.
Aplicación aquí	Exploración, selección de atributos, clasificación, regresión y clustering.	No es necesario para 13,611 filas; se estudiará como marco para una futura colección masiva de imágenes.
Herramientas	Python, SQL, scikit-learn, Orange, Weka, Power BI.	Spark, Hadoop, Kafka, almacenes de objetos y plataformas cloud.

Conclusión comparativa

Los cuatro conceptos no son sinónimos. IA es el campo general; ML aporta algoritmos que aprenden; Data Mining organiza la búsqueda de patrones con un propósito; Big Data resuelve problemas de escala e infraestructura. Para Dry Bean son pertinentes ML y Data Mining. Adoptar una plataforma Big Data sería desproporcionado en esta fase, aunque sus principios de trazabilidad y gobierno sí son valiosos.

6. Lenguaje, bibliotecas y herramientas

Componente	Propuesta	Justificación y uso
Lenguaje	Python 3	Ecosistema maduro, sintaxis legible y compatibilidad con análisis, ML y automatización.
Datos	pandas y NumPy	Lectura de Excel/CSV, perfilado, transformación vectorizada y matrices numéricas.
Visualización	Matplotlib y Seaborn	Distribuciones, relaciones, matriz de confusión, residuos y comparación de modelos.
Modelado	scikit-learn	Pipelines, preprocesamiento, validación cruzada, métricas, clasificación, regresión, PCA y clustering.
Entorno	Jupyter Notebook / VS Code	Exploración narrativa y código modular reproducible.
Base de datos	PostgreSQL	Construcción posterior de un Data Mart con SQL, integridad, vistas y conexión con BI.
Versionado	Git y GitHub	Historial de cambios, respaldo remoto, evidencias y colaboración verificable.
Tablero	Power BI	Comunicación interactiva de perfiles, clases, métricas y hallazgos para público no técnico.

Criterios técnicos

- Semilla aleatoria fija y versiones de dependencias registradas para facilitar reproducción.
- Pipeline de scikit-learn para que el escalado y cualquier transformación se ajusten solo con entrenamiento.
- GitHub almacenará código y documentación; los datos originales permanecerán sin modificaciones en data/raw.
- PostgreSQL y Power BI se incorporarán cuando la fase de Data Mart y comunicación lo requiera; no se forzarán en la exploración inicial.

La documentación oficial de scikit-learn recomienda separar evaluación y ajuste mediante validación, y sus pipelines ayudan a evitar que el preprocesamiento utilice información del conjunto de prueba (scikit-learn developers, 2026).

7. Metodología CRISP-DM

CRISP-DM (Cross-Industry Standard Process for Data Mining) organiza un proyecto en seis fases conectadas. No es una secuencia rígida: la evidencia puede obligar a regresar, redefinir objetivos o preparar nuevamente los datos. Se elige porque alinea preguntas, calidad, modelado, evaluación y entrega en un ciclo auditable, y porque se adapta al calendario académico (IBM, 2026).



Fase	Propósito	Entregable del proyecto
1. Comprensión del negocio	Definir problema, interesados, metas y criterios de éxito.	Pregunta rectora, objetivos, alcance y riesgos.
2. Comprensión de datos	Recolectar, describir, explorar y verificar calidad.	Diccionario, perfilado, visualizaciones y reporte de calidad.
3. Preparación	Seleccionar, limpiar, integrar y transformar.	Dataset procesado, Data Mart, reglas y pipeline.
4. Modelado	Elegir técnicas, entrenar y ajustar modelos.	Clasificadores, regresores, clustering y PCA.
5. Evaluación	Validar resultados contra objetivos y riesgos.	Métricas, comparación, errores y conclusiones.
6. Despliegue	Comunicar y poner los resultados a disposición.	Dashboard, informe, presentación y repositorio final.

8. Aplicación preliminar de CRISP-DM

Fase	Acciones previstas	Criterio de avance
Negocio	Traducir la clasificación visual en pregunta analítica; acordar precisión e interpretabilidad como metas.	Objetivos verificables y riesgos documentados.
Datos	Validar esquema, tipos, faltantes, duplicados, rangos, correlaciones y distribución de Class.	Diccionario completo y hallazgos reproducibles.
Preparación	Eliminar duplicados antes del split; conservar raw; escalar cuando corresponda; crear partición estratificada.	Pipeline sin fuga y conjunto procesado versionado.
Modelado	Comparar regresión lineal/árboles para Area; logística, SVM, k-NN y Random Forest para Class; PCA y k-means para estructura.	Modelos base y ajustados bajo el mismo protocolo.
Evaluación	Clasificación: macro F1, accuracy y confusión. Regresión: MAE, RMSE y R^2. Clustering: silhouette y contraste con Class.	Selección razonada; análisis de errores y límites.
Despliegue	Tablero de Power BI, informe técnico, README y presentación con evidencia en GitHub.	Artefactos accesibles, coherentes y defendibles.

Criterios preliminares de éxito

Dimensión	Criterio
Reproducibilidad	Un tercero puede ejecutar el flujo desde el repositorio y obtener las mismas particiones y métricas.
Clasificación	Superar una línea base simple y sostener macro F1 consistente en validación cruzada y prueba.
Regresión	Reducir MAE/RMSE frente a predecir la media, sin variables con relación determinística al objetivo.
Interpretación	Explicar variables importantes, clases confundidas y límites sin presentar causalidad no demostrada.
Comunicación	Dashboard y reporte responden la pregunta principal y documentan decisiones.

9. Diseño analítico preliminar

Clasificación multiclase

La etiqueta Class ya contiene siete categorías oficiales, por lo que no se crearán cortes artificiales. Se realizará una partición estratificada y se compararán modelos simples e interpretables con modelos no lineales. Macro F1 tendrá prioridad porque pondera cada clase por igual; accuracy se reportará como apoyo. La matriz de confusión mostrará qué variedades se parecen morfológicamente.

Regresión

Se propone Area como variable continua a estimar. EquivDiameter se excluirá porque se calcula directamente a partir del área, y ConvexArea se revisará o excluirá del modelo principal por su fuerte dependencia geométrica. Esta decisión evita una predicción trivial y permite medir cuánto explican el perímetro, los ejes y los factores de forma. No se discretizará Area: hacerlo perdería información y convertiría el problema en clasificación.

Análisis no supervisado

Tras estandarizar las 16 variables, PCA permitirá visualizar los ejes de mayor variación y k-means servirá como punto de partida para buscar grupos. Se elegirá el número de grupos mediante silhouette y análisis exploratorio, no imponiendo siete de manera automática. Luego se contrastarán los clusters con Class solo para interpretar coincidencias, sin usar la etiqueta durante el ajuste.

Plan de evaluación y control

Riesgo	Control
Fuga de información	Deduplicación antes del split y transformaciones ajustadas dentro de pipeline.
Sobreajuste	Validación cruzada, conjunto de prueba reservado y complejidad controlada.
Desbalance	Estratificación, macro F1, recall por clase y matriz de confusión.
Selección sesgada	Mismo protocolo y métricas para todos los modelos; decisiones registradas.

10. Resultados esperados

Resultado	Evidencia prevista
Perfil confiable del conjunto	Diccionario, estadísticas, distribuciones, duplicados y relaciones entre atributos.
Dataset preparado	Copia procesada separada del original, reglas de transformación y esquema de Data Mart.
Modelo de clasificación	Comparación de algoritmos, macro F1, accuracy y matriz de confusión.
Modelo de regresión	Estimación de Area con MAE, RMSE, R^2 y revisión de residuos.
Estructura no supervisada	PCA, clusters, silhouette y comparación descriptiva con variedades.
Interpretación	Atributos relevantes, clases difíciles y limitaciones de generalización.
Comunicación	Dashboard, informe final, presentación y repositorio actualizado.

Tres preguntas derivadas

- ¿Qué variables de tamaño y forma aportan mayor capacidad para distinguir las siete variedades?
- ¿Entre qué pares de variedades se concentran los errores de clasificación y qué rasgos comparten?
- ¿Los grupos obtenidos sin utilizar Class coinciden con las variedades registradas o revelan estructuras alternativas?

Supuestos de interpretación

Los resultados describirán el conjunto disponible y su proceso de captura. Una importancia alta de una variable no probará causalidad biológica. Tampoco se afirmará que el modelo sustituye una validación agronómica o que funcionará con imágenes tomadas bajo condiciones distintas sin una prueba externa.

11. Cronograma preliminar

Alineado al calendario oficial del recursamiento 2026.

Fecha	Hito	Actividades y evidencia
25 sep	Actividad 0	Identificación, descarga, revisión inicial y repositorio GitHub.
2 oct	Unidad I · 20 %	Planeación formal, objetivos, CRISP-DM, herramientas y cronograma.
9 oct	Revisión UII	Diccionario, exploración, limpieza inicial y propuesta de DW/Data Mart.
16 oct	Unidad II · 15 %	ETL, datos procesados, esquema DW/Data Mart y repositorio.
23 oct	Revisión UIII	Regresión y clasificación funcionando.
30 oct	Unidad III · 25 %	Modelos, métricas, evaluación, optimización e informe.
6 nov	Revisión UIV	Clustering y reducción de dimensionalidad funcionando.
13 nov	Unidad IV · 25 %	Modelos no supervisados, evaluación, interpretación e informe.
17 nov	Revisión UV	Dashboard y storytelling preliminar.
20 nov	Unidad V · 15 %	Dashboard, repositorio final, informe y defensa.

Gestión del seguimiento

Cada hito se registrará mediante commits descriptivos. Las revisiones obligatorias se usarán para validar decisiones antes de continuar; no sustituyen las entregas evaluables. Los cambios de alcance, variables o métricas quedarán documentados en el README y en los informes de cada unidad.

Repositorio

https://github.com/Kaysito/REC_ECBD_2026_Hernandez_Trejo_Kevin

12. Fuentes de información

Referencias en formato APA (7.ª edición).

IBM. (2026). CRISP-DM help overview. IBM Documentation. https://www.ibm.com/docs/en/spss-modeler/saas?topic=dm-crisp-help-overview

Koklu, M., & Özkan, I. A. (2020). Multiclass classification of dry beans using computer vision and machine learning techniques. Computers and Electronics in Agriculture, 174, 105507. https://doi.org/10.1016/j.compag.2020.105507

National Institute of Standards and Technology. (2026). Artificial intelligence. Computer Security Resource Center Glossary. https://csrc.nist.gov/glossary/term/artificial_intelligence

National Institute of Standards and Technology. (2019). NIST Big Data Interoperability Framework: Volume 1, Definitions (NIST SP 1500-1r2). https://doi.org/10.6028/NIST.SP.1500-1r2

pandas development team. (2026). pandas documentation. https://pandas.pydata.org/docs/

Python Software Foundation. (2026). Python 3 documentation. https://docs.python.org/3/

scikit-learn developers. (2026). scikit-learn user guide. https://scikit-learn.org/stable/user_guide.html

Tabassi, E. (2023). Artificial Intelligence Risk Management Framework (AI RMF 1.0) (NIST AI 100-1). National Institute of Standards and Technology. https://doi.org/10.6028/NIST.AI.100-1

UCI Machine Learning Repository. (2020). Dry Bean [Data set]. https://doi.org/10.24432/C50S4B

Nota de integridad académica

La planeación distingue decisiones propuestas de resultados aún no obtenidos. Las métricas finales se reportarán únicamente después de ejecutar y documentar los experimentos. Las fuentes se utilizan para sustentar definiciones, metodología, herramientas y procedencia del conjunto de datos.